

ROTEIRO 2

Classificação supervisionada de *intrusão*

Do sinal heurístico ao parecer sobre um modelo real.

CIBERSEGURANÇA APLICADA COM INTELIGÊNCIA ARTIFICIAL · 2026-2 · AULA 5 · 27/08/2026

FORMATO	PESO	PRÉ-REQUISITOS	CONTEÚDO
Duplas · notebook Jupyter + relatório PDF	1/6 da nota de roteiros (rubrica, seção 7)	Roteiro 1 · Python básico · pandas · Aula 5	Aquecimento (b-d) e CICIDS2017 real (e-l)

1. Objetivos de aprendizagem

Ao concluir este roteiro, você deverá ser capaz de:

1. Explicar o fluxo completo de um problema de classificação supervisionada: dados brutos → features e labels → treino/teste → modelo → avaliação.
2. Transformar sinais heurísticos (contagens, razões e frequências extraídas de logs) em uma matriz de features tabular pronta para o scikit-learn.
3. Treinar, comparar e interpretar uma árvore de decisão, uma regressão logística e um Random Forest, identificando quando cada um é preferível.
4. Auditar um dataset real de segurança (CICIDS2017): encontrar defeitos conhecidos e problemas plantados (vazamento, rótulos impossíveis, quase-duplicatas) com código, não com intuição.
5. Comparar avaliação aleatória e temporal, explicar em termos de rede por que o modelo cai, e escrever um parecer técnico fundamentado em números próprios.

2. Ambiente e dados

2.1 • FERRAMENTAS (TODAS LIVRES)

FERRAMENTA	USO NESTE ROTEIRO
Python 3.10+ • Jupyter	Notebook do aluno (entregável)
pandas • numpy	Carga, limpeza e engenharia de features
scikit-learn ≥ 1.3	Modelos, split, métricas
matplotlib	Árvore de decisão, importâncias, matriz de confusão
Google Colab (opcional)	Se não quiser instalar nada; suba o pool (19 MB) e rode meu_dataset.py lá

Instalação: `pip install pandas numpy scikit-learn matplotlib jupyter`

2.2 · DATASETS: CADA DUPLA TEM O SEU

Pacote `roteiro2-dados.zip` (Blackboard). Contém:

ARQUIVO	DESCRIÇÃO
<code>dados/aquecimento_autenticacao.csv</code>	Aquecimento (itens b), c) e d)). Dataset sintético de 3.160 IPs, 8 sinais agregados de autenticação (mesma natureza dos sinais do R1), rótulo benigno / brute_force (~15% de ataque). Igual para todas as duplas.
<code>pool/cicids2017_pool.csv.gz</code>	182 mil fluxos amostrados dos 8 dias do CICIDS2017 real (UNB, 2017), com colunas de contexto adicionadas (dia, turno, ordem_captura) e as armadilhas plantadas. Não use diretamente.
<code>meu_dataset.py</code>	Gera o SEU arquivo a partir do pool: <code>python meu_dataset.py --dupla "Nome Sobrenome; Nome Sobrenome"</code> . Imprime o código da dupla, o random_state obrigatório e a classe difícil sorteada.
<code>dados/R2_<código>.csv.gz</code>	Núcleo (itens e) a k)). ~111 mil fluxos × 83 colunas, 15 rótulos. É diferente para cada dupla; os números do relatório são conferidos contra ele.

O dicionário das colunas está no Anexo A. Referência do dataset: Sharafaldin, Lashkari & Ghorbani (ICISSP 2018).

3. Atividade

Um único notebook, com uma seção por item (a) até l)). Trabalhe em dupla. Os itens são sequenciais: cada um usa o resultado do anterior.

ITEM	O QUÊ	DATASET
<i>a</i>	Gerar o dataset da dupla	pool
<i>b</i>	Aquecimento: carregar, X/y, regra do Roteiro 1 como baseline	aquecimento
<i>c</i>	Split estratificado e árvore de decisão rasa	aquecimento
<i>d</i>	Regressão logística com Pipeline; experimento sem scaler	aquecimento
<i>e</i>	CICIDS2017 real: diagnóstico, caçada às armadilhas, limpeza	R2_<código>
<i>f</i>	Separabilidade por feature única: prove	R2_<código>
<i>g</i>	Engenharia de features testada na classe difícil	R2_<código>
<i>h</i>	Random Forest: split aleatório vs. temporal	R2_<código>
<i>i</i>	Importância das features	R2_<código>
<i>j</i>	Mergulho na classe difícil	R2_<código>
<i>k</i>	Parecer contra a produção	—
<i>l</i>	Ataques nunca vistos: treinar com segunda a quinta, testar na sexta; questões; ficha	R2_<código>

3.1 · PREPARAÇÃO

a) Gerar o dataset da dupla

- Rode `python meu_dataset.py --dupla "Nome Sobrenome; Nome Sobrenome"`. Cole a saída completa na primeira célula do notebook: código da dupla, random_state e classe difícil. **Use esse random_state em todo split e modelo do roteiro.**

3.2 · AQUECIMENTO: OS SINAIS DO ROTEIRO 1 VIRAM UM CLASSIFICADOR

Dataset: `aquecimento_autenticacao.csv`. Objetivo: ver, com dados pequenos e limpos, o fluxo completo X/y, split, modelo e avaliação antes de enfrentar dados sujos.

b) Carregar, X/y e baseline

- Carregue o CSV. Mostre `shape`, `head()`, `describe()` e a contagem de rótulos. Qual a proporção de ataque? Alguma feature tem escala muito diferente das outras?
- Separe X e y (y como 0/1). Retire `ip_origem` e escreva no notebook por que ele não pode ser feature.
- Escreva UMA regra booleana em pandas no estilo do Roteiro 1 (ex.: `falhas >= 10 & usuarios_inexistentes >= 1`). Calcule acurácia e matriz de confusão da regra contra y. Abra as linhas que ela errou: o que esses IPs têm em comum?

c) Split e árvore de decisão

- `train_test_split` 70/30, `stratify=y`, com o `random_state` da dupla. Confirme a proporção de ataque nos dois conjuntos.
- `DecisionTreeClassifier(max_depth=3)`. Treine no treino, avalie no teste: acurácia, matriz de confusão, `classification_report`.
- Plote a árvore (`plot_tree`) e compare com sua regra: quais features a árvore escolheu no 1º e 2º nível? Ela reinventou sua regra ou achou outra?

Regra de ouro. Tudo o que o modelo aprende, inclusive escalas e limiares, vem SÓ do treino. O teste é aberto uma vez, no fim. Quem ajusta olhando o teste está medindo memorização, não generalização.

d) Regressão logística com Pipeline

- `Pipeline([('scaler', StandardScaler()), ('clf', LogisticRegression(max_iter=1000))])`. Avalie da mesma forma; plote os coeficientes por feature (positivo empurra para ataque). Faz sentido físico?
- **Experimento obrigatório:** retreine SEM o scaler. Compare acurácia e `n_iter_`. O que mudou e por quê?
- Monte a tabela regra manual × árvore × regressão logística (acurácia, FN, FP).

3.3 · NÚCLEO: CICIDS2017 REAL, DA LIMPEZA AO PARECER

Dataset: o SEU arquivo `dados/R2_<código>.csv.gz`. Cada linha é um fluxo de rede (CICFlowMeter), 79 features originais + 4 colunas de contexto, 15 rótulos.

Aviso: este dataset tem armadilhas. Além dos defeitos conhecidos do CICIDS2017 (Infinity, NaN, duplicatas, nomes com espaço, colunas constantes ou duplicadas), plantei TRÊS problemas adicionais no arquivo. Não vou dizer quais. Encontrá-los, explicá-los e tratá-los faz parte do item e) e vale 2,0 pontos. Dica: nenhum deles aparece em `describe()`; todos aparecem para quem pergunta "de onde veio esta coluna?", "este vetor pode ter dois rótulos?" e "o que `drop_duplicates()` NÃO pega?".

e) Diagnóstico e limpeza

- Carregue com `encoding='latin-1'`. Conte: colunas com espaço inicial, $\pm$ Infinity, NaN, duplicatas exatas, colunas constantes, colunas idênticas a outra. Mostre a distribuição de rótulos.
- **Caçada às armadilhas.** Para cada uma que encontrar: (1) como detectou (código), (2) quantas linhas ou colunas afeta, (3) por que é um problema para o modelo, (4) o que fez com ela. Uma armadilha só descrita, sem código de detecção, não pontua.
- Registre a contagem de linhas removidas em cada passo da limpeza e a forma final da tabela.

f) Separabilidade por feature única: prove

- Para cada classe de ataque do seu arquivo: existe UMA feature que, com um único limiar, atinge recall $\geq 0,9$ e precisão $\geq 0,5$ contra BENIGN? Produza a tabela classe $\times$ melhor feature $\times$ recall $\times$ precisão $\times$ limiar. (Sugestão: `DecisionTreeClassifier(max_depth=1)` por feature.)
- Para a sua classe difícil, mostre com um histograma sobreposto (classe vs. BENIGN) por que nenhuma feature isolada resolve.
- Só depois escreva, para 3 classes à sua escolha, a explicação de rede de por que aquela feature separa (ou não).

g) Engenharia de features: cada uma tem de ser testada

- Crie ≥ 4 features derivadas com justificativa de rede. Para cada uma, meça o efeito na separabilidade isolada da sua classe difícil (mesmo teste do item f). Uma feature que não ajuda continua valendo se o teste estiver documentado; o que não vale é feature sem teste.

h) Random Forest: split aleatório vs. split temporal

- Split aleatório 70/30 estratificado com o seu `random_state`;
`RandomForestClassifier(n_estimators=200)`. Acurácia, macro-F1, `classification_report`, matriz de confusão.
- **Split temporal por campanha:** dentro de cada par (dia, rótulo), os fluxos com `ordem_captura` nos primeiros 70% treinam; os últimos 30% testam. Mesmo modelo, mesmas features. Tabela recall por classe: aleatório × temporal.
- Quais classes caem? Levante UMA hipótese de rede para a maior queda e verifique-a com uma tabela de medianas início × fim da campanha.

i) Importância das features

- `feature_importances_` top-15. Suas features derivadas apareceram? Se uma feature "boa demais" aparecer no topo, volte ao item e).

j) Mergulho na classe difícil

- Com quem a classe é confundida em cada split? Proponha UMA feature nova (calculável a partir das existentes), implemente, retreine no split temporal e reporte o efeito. Se não ajudar, diga por quê com evidência (medianas, histogramas). Uma resposta honesta "não resolve, e o motivo é X" vale nota cheia.

k) Parecer contra a produção

- Cenário: um gestor viu a acurácia de 98% do split aleatório e quer colocar o modelo no IDS da empresa na segunda-feira. Escreva um parecer de UMA página contra, com pelo menos cinco argumentos, cada um ancorado em um número do seu próprio notebook (itens e) a j)). Argumentos genéricos sem número não contam.

l) Ataques nunca vistos: treinar com segunda a quinta, testar na sexta

- Treine o mesmo Random Forest apenas nos fluxos de segunda a quinta e teste na sexta (`dia == 'sex'`). Na sexta há Bot, PortScan e DDoS, que não existem nos outros dias: o que o modelo faz com eles? Reporte a matriz de confusão da sexta e explique, em uma página no máximo, o que esse experimento diz sobre um IDS enfrentar um ataque que nunca viu.
- Responda as questões da seção 5 e preencha a ficha de resultados (Anexo B).

4. Entregáveis

ENTREGÁVEL	CONTEÚDO	FORMATO / NOME
Notebook	Seções a) a l), executado do início ao fim (Kernel → Restart & Run All) com saídas visíveis. Código comentado.	R2_<dupla>.ipynb
Relatório	Máx. 6 páginas: tabela-síntese do aquecimento; armadilhas encontradas (detecção, impacto, tratamento); tabela de separabilidade; recall aleatório x temporal; parecer contra a produção (1 página); respostas Q1-Q8.	R2_<dupla>.pdf
Ficha de resultados	Anexo B preenchido (uma página), me permite comparar todas as duplas rapidamente.	Dentro do PDF (última página)

Um envio por dupla, pelo Blackboard.

5. Questões para o relatório

AQUECIMENTO (ITENS B), C) E D))

- 1 Quais features a árvore escolheu nos dois primeiros níveis? Isso coincide com a regra que você escreveu no item b? Se não, qual das duas você colocaria em produção e por quê?
- 2 O que aconteceu com a regressão logística sem o StandardScaler (acurácia e número de iterações)? Explique o mecanismo.
- 3 Por que `ip_origem` não pode ser feature? Descreva o que o modelo "aprenderia" se você o incluísse e o que aconteceria no teste.

CICIDS2017 (ITENS E) A J))

- 4 Liste as armadilhas que encontrou. Para a que considera mais perigosa: que acurácia o modelo teria se ela ficasse, e por que esse número seria mentira?

- 5 Quais classes são separáveis por uma única feature e quais não? Explique, em termos de rede, a diferença entre uma classe separável e a sua classe difícil.

- 6 Qual classe mais caiu do split aleatório para o temporal? Mostre a evidência (medianas início × fim) e explique o que mudou no comportamento do atacante.

- 7 O split temporal é uma avaliação "injusta" com o modelo, ou é a única honesta? Argumente com o que aconteceria em produção.

- 8 Sua feature do item j ajudou? Se sim, quanto e por quê; se não, o que isso revela sobre o limite de "engenharia de features" diante de drift?

6. Rubrica de avaliação (10 pontos)

CRITÉRIO	PONTOS	O QUE SE ESPERA PARA PONTUAÇÃO MÁXIMA
A. Pipeline correto	1,5	Split estratificado antes de qualquer ajuste; scaler dentro do Pipeline; sem vazamento de teste; seed fixa; notebook roda de ponta a ponta.
B. Baseline e comparação (itens b, c, d)	1,0	Regra manual implementada e avaliada; tabela regra × árvore × logística com FN/FP; leitura correta da árvore.
C. Auditoria do dataset (item e)	2,0	Defeitos conhecidos tratados com contagens; as 3 armadilhas encontradas com código de detecção, impacto e tratamento (0,5 por armadilha + 0,5 pela limpeza).
D. Prova de separabilidade e features (itens f, g)	1,5	Tabela completa classe × feature; histograma da classe difícil; ≥ 4 features derivadas, cada uma com teste documentado.
E. Avaliação temporal e interpretação (itens h, i, j)	2,0	Recall aleatório × temporal por classe; hipótese de rede verificada com medianas; classe difícil investigada com evidência, ajudando ou não.
F. Parecer e comunicação (item k)	1,0	Parecer com ≥ 5 argumentos, cada um com número próprio; ≤ 6 páginas; Anexo B; Q1-Q8 objetivas.
G. Ataques nunca vistos (item l)	1,0	Modelo treinado com segunda a quinta e testado na sexta: matriz de confusão da sexta; explicação do que acontece com as classes que só existem na sexta e o que isso implica para um IDS.

7. Erros comuns e dicas

- Ajustar o scaler no dataset inteiro e só depois fazer o split: vazamento. O Pipeline resolve.
- Comemorar 99% de acurácia. Com ~58% de BENIGN, um modelo que diz "tudo benigno" já tem 58%. Olhe o recall por classe.
- Substituir Infinity por 0. Zero bytes/s é o oposto de "duração zero com bytes". Remova ou marque a linha.

- Confiar na feature com maior correlação. Em segurança, a coluna que "prevê tudo" costuma ter sido gerada depois do rótulo. Pergunte de onde ela veio.
- Deixar a IA generativa decidir o que é um problema. Ela não vê o seu arquivo. Todo achado precisa de código rodado sobre o seu dataset e de um número que só existe nele.
- Esquecer o `encoding='latin-1'` e quebrar no rótulo Web Attack.
- Escolher features pela importância e depois retreinar no mesmo teste (seleção com vazamento). Se for selecionar, use validação dentro do treino.
- Random Forest com `n_jobs=-1` no Colab gratuito pode demorar; 100 árvores bastam para explorar.

8. Leituras obrigatórias

- GÉRON, A. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow*. 3. ed. Alta Books, 2023. Capítulos 1 (panorama), 2 (projeto ponta a ponta, foque em split treino/teste, pipelines e transformadores) e 3 (classificação, até matriz de confusão, precisão e recall).
- CHIO, C.; FREEMAN, D. *Machine Learning and Security*. O'Reilly, 2018. Capítulo 2 (Classifying and Clustering); disponível no acervo do projeto.
- SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. *Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization*. ICISSP, 2018. Seções 3-4 (como o CICIDS2017 foi gerado e quais ataques contém). Artigo curto, gratuito.
- Documentação: scikit-learn, `train_test_split`, `DecisionTreeClassifier`, `RandomForestClassifier`, `Pipeline`, `classification_report`.

Complementar: HALDER, S.; OZDEMIR, S. *Hands-On Machine Learning for Cybersecurity*. Packt, 2018. Cap. 1-2 (no acervo).

Anexo A • Dicionário de features

A.1 • AQUECIMENTO_AUTENTICACAO.CSV (POR IP DE ORIGEM, JANELA DE 24 H)

FEATURE	SIGNIFICADO
tentativas_total	Total de eventos de autenticação do IP na janela
falhas	Tentativas com resultado 'Failed password' / 'Invalid user'
usuarios_distintos	Quantidade de logins diferentes tentados
intervalo_medio_seg	Tempo médio entre tentativas consecutivas (s)
fracao_noturna	Fração das tentativas entre 0h e 6h
usuarios_inexistentes	Tentativas contra logins que não existem no sistema
sucesso_apos_falhas	1 se houve login bem-sucedido após ≥ 1 falha
portas_distintas	Portas de destino distintas (22, 2222, ...)
label	benigno / brute_force

A.2 • CICIDS2017 (POR FLUXO, CICFLOWMETER, 79 FEATURES + CONTEXTO)

As 79 features originais seguem a documentação do CICFlowMeter (Lashkari et al., github.com/ahlashkari/CICFlowMeter). Famílias:

FAMÍLIA	COLUNAS (EXEMPLOS) E SIGNIFICADO
Identificação	Destination Port
Volume	Total Fwd/Backward Packets; Total Length of Fwd/Bwd Packets; Flow Bytes/s; Flow Packets/s; Fwd/Bwd Packets/s; Subflow *
Tamanho de pacote	Fwd/Bwd Packet Length Max/Min/Mean/Std; Min/Max/Mean/Std/Variance Packet Length; Average Packet Size; Avg Fwd/Bwd Segment Size
Tempo	Flow Duration; Flow IAT Mean/Std/Max/Min; Fwd/Bwd IAT Total/Mean/Std/Max/Min; Active Mean/Std/Max/Min; Idle Mean/Std/Max/Min
Flags TCP	FIN/SYN/RST/PSH/ACK/URG/CWE/ECE Flag Count; Fwd/Bwd PSH/URG Flags
Cabeçalho e janela	Fwd/Bwd Header Length; Init_Win_bytes_forward/backward; act_data_pkt_fwd; min_seg_size_forward; Down/Up Ratio
Bulk (sempre zero nesta versão)	Fwd/Bwd Avg Bytes/Bulk, Avg Packets/Bulk, Avg Bulk Rate
Contexto (adicionado)	dia (seg...sex); turno; ordem_captura (posição da linha no CSV original do dia = ordem temporal aproximada)
Label	BENIGN · DDoS · PortScan · Bot · DoS Hulk/GoldenEye/slowloris/Slowhttptest · Heartbleed · FTP-Patator · SSH-Patator · Web Attack Brute Force/XSS/Sql Injection · Infiltration

Qualquer outra coluna que você encontrar no arquivo não pertence ao CICFlowMeter. Pergunte-se de onde ela veio.

Anexo B • Ficha de resultados (preencher e anexar ao relatório)

Dupla: _____ Data: ____/____/2026

AQUECIMENTO

MODELO	ACURÁCIA	FN	FP	RECALL ATAQUE
Regra manual (item b))				
Árvore d=3				
Reg. logística (com scaler)				
Reg. logística (sem scaler)				

Features do 1º e 2º nível da árvore: _____

CICIDS2017

Código da dupla: _____ random_state: _____ classe
difícil: _____

ARMADILHA / PASSO DE LIMPEZA	LINHAS (OU COLUNAS) AFETADAS
Inf / NaN	
Duplicatas exatas	
Armadilha 1: _____	
Armadilha 2: _____	
Armadilha 3: _____	
Total final (linhas × colunas)	

	ACURÁCIA	MACRO-F1	RECALL CLASSE DIFÍCIL	RECALL BENIGN
Split aleatório				
Split temporal				
Classes separáveis por uma feature: _____				
Classe que mais caiu no temporal: _____ de _____ para _____				
Feature do item j: _____ efeito no recall temporal: _____ → _____				

Fim do Roteiro 2 · Cibersegurança Aplicada com Inteligência Artificial · Insper 2026-2